

LAPORAN MACHINE LEARNING

Introduction to Machine Learning with Python

Chapter 2: Supervised Learning & Chapter 3: Unsupervised Learning and Preprocessing



Disusun Oleh:

Nama : Aisyah Azzahrah

NPM : G1A024033

Kelas:

Informatika (A)

Dosen Pengampu:

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK


UNIVERSITAS BENGKULU

2026

Percobaan Chapter 2 — Supervised Learning

A. Klasifikasi K-Nearest Neighbors (KNN)

Percobaan ini menguji pengaruh jumlah tetangga ($n_neighbors$) terhadap akurasi model KNN pada dataset Breast Cancer (569 sampel, 30 fitur, 2 kelas: malignant/benign). Data dibagi menjadi 75% data latih dan 25% data uji.




Gambar 1 Akurasi training dan test KNN terhadap jumlah tetangga ($n_neighbors = 1-20$)

Hasil menunjukkan bahwa dengan $n_neighbors = 1$, model mengalami overfitting (akurasi training = 100%, akurasi test = 90,21%). Akurasi test terbaik dicapai pada $n_neighbors = 6$ dengan akurasi 93,71%, sesuai dengan konsep trade-off kompleksitas model yang dibahas pada buku: model terlalu sederhana (k besar) maupun terlalu kompleks ($k=1$) sama-sama menurunkan akurasi generalisasi.

B. Regresi Linear, Ridge, dan Lasso

Percobaan ini membandingkan tiga model regresi linear pada data sintesis satu-fitur yang diperluas menjadi fitur polinomial derajat 8 (untuk menciptakan kondisi berdimensi tinggi, mirip semangat percobaan 'extended boston' pada buku).




Gambar 2 Perbandingan kurva hasil regresi Linear Regression, Ridge, dan Lasso

Model	R ² Training	R ² Test	Keterangan
Linear Regression	0.7765	0.7297	Tanpa regularisasi
Ridge (alpha=1.0)	0.7765	0.7288	Regularisasi L2
Lasso (alpha=0.01)	0.7763	0.7304	Regularisasi L1, hanya 7 dari fitur polinomial yang digunakan

Lasso menghasilkan R² test tertinggi sekaligus melakukan seleksi fitur otomatis (banyak koefisien menjadi nol), sesuai dengan sifat regularisasi L1 yang dijelaskan pada buku.

C. Logistic Regression: Pengaruh Parameter C

Parameter C pada Logistic Regression mengatur kekuatan regularisasi: semakin besar C, semakin lemah regularisasi (model semakin kompleks).




Gambar 3 Akurasi Logistic Regression terhadap nilai parameter C (skala logaritmik)

C	Akurasi Training	Akurasi Test
0.01	0.9601	0.9371
0.1	0.9648	0.9441
1	0.9789	0.9441
10	0.9765	0.9510
100	0.9859	0.9650


Pada rentang C yang diuji, peningkatan C cenderung meningkatkan akurasi test pada dataset ini, menunjukkan model masih berada pada sisi underfitting untuk C kecil.

D. Decision Tree: Pengaruh Kedalaman Pohon



Gambar 4 Akurasi Decision Tree terhadap kedalaman maksimum pohon (*max_depth*)

Akurasi test terbaik (92,31%) dicapai pada *max_depth* = 3. Setelah titik ini, akurasi training terus meningkat mendekati 100% sementara akurasi test cenderung stagnan/menurun — indikasi overfitting seiring bertambahnya kedalaman pohon.



Gambar 5 Sepuluh fitur terpenting menurut Decision Tree (*max_depth*=4)

E. Random Forest

Random Forest dengan 100 pohon ($n_estimators=100$) menghasilkan akurasi training 100% dan akurasi test 95,80%, lebih tinggi dan lebih stabil dibandingkan satu Decision Tree tunggal, karena efek averaging dari banyak pohon acak mengurangi overfitting.

F. Kesimpulan Chapter 2

Algoritma	Akurasi/Skor Test Terbaik	Catatan
KNN ($k=6$)	93.71%	Rawan overfitting pada k kecil
Logistic Regression ($C=100$)	96.50%	Performa terbaik pada percobaan klasifikasi
Decision Tree ($depth=3$)	92.31%	Mudah diinterpretasi, rawan overfitting
Random Forest (100 pohon)	95.80%	Lebih stabil dari single tree

Chapter 3 -Unsupervised Learning and Preprocessing

A. Pengaruh Preprocessing (Feature Scaling) terhadap SVM


Support Vector Machine (SVM) sangat sensitif terhadap skala fitur. Percobaan ini membandingkan akurasi SVM ($C=100$) pada data Breast Cancer sebelum dan sesudah distandarisasi menggunakan StandardScaler.

Kondisi Data	Akurasi Test
Tanpa scaling	93.71%
Dengan StandardScaler	96.50%

Scaling meningkatkan akurasi secara signifikan, menegaskan pentingnya tahap preprocessing sebelum melatih model berbasis jarak/margin seperti SVM.

B. Reduksi Dimensi dengan PCA

Principal Component Analysis (PCA) diterapkan pada data Breast Cancer yang telah distandarisasi, mereduksi 30 fitur menjadi 2 komponen utama untuk keperluan visualisasi.




Gambar 3.1 Proyeksi data Breast Cancer ke 2 komponen utama (PCA), dipisahkan berdasarkan kelas malignant/benign


Dua komponen utama pertama menjelaskan sekitar 63,24% dari total variansi data ($44,27\% + 18,97\%$). Meskipun hanya menggunakan 2 dari 30 fitur asli, kedua kelas (malignant dan benign) masih tampak cukup terpisah pada plot, menunjukkan PCA berhasil mempertahankan sebagian besar informasi yang relevan untuk membedakan kelas.

C. Clustering dengan K-Means

K-Means diterapkan pada hasil reduksi PCA. Metode elbow digunakan untuk membantu menentukan jumlah cluster (k) yang sesuai.



Gambar 3.2 Kurva metode elbow (inertia vs jumlah cluster k)




Gambar 3.3 Hasil clustering K-Means ($k=2$) beserta titik centroid

Dengan $k=2$, hasil cluster K-Means memiliki kesesuaian sebesar 90,69% terhadap label kelas asli (malignant/benign) — cukup tinggi mengingat K-Means sama sekali tidak menggunakan informasi label selama pelatihan, murni berdasarkan kedekatan jarak antar titik data.

D. Hierarchical (Agglomerative) Clustering

Agglomerative Clustering dengan linkage Ward diterapkan pada subset 40 sampel data hasil PCA untuk menghasilkan dendrogram yang mudah dibaca, serta pada seluruh data untuk evaluasi kuantitatif.




Gambar 3.4 Dendrogram hasil Agglomerative Clustering (linkage Ward, subset 40 sampel)

Pada seluruh data ($k=2$), Agglomerative Clustering menghasilkan kesesuaian 90,69% terhadap label asli — identik dengan hasil K-Means pada percobaan ini, menunjukkan struktur dua kelompok pada data cukup jelas terlihat oleh kedua metode.

E. DBSCAN vs K-Means pada Data Non-Linear (two_moons)

Untuk menunjukkan keterbatasan K-Means pada bentuk cluster non-konveks, percobaan dilakukan pada dataset sintetis two_moons yang berbentuk dua bulan sabit yang saling berkelindan.



Gambar 3.5 Perbandingan hasil clustering K-Means (kiri) dan DBSCAN (kanan) pada data two_moons

K-Means gagal memisahkan kedua bentuk bulan sabit dengan benar karena hanya mampu membentuk cluster berbentuk cembung (convex). Sebaliknya, DBSCAN berhasil menemukan

2 cluster sesuai bentuk data yang sebenarnya (dengan 1 titik terdeteksi sebagai noise), karena DBSCAN bekerja berdasarkan kepadatan (density) titik data, bukan jarak ke centroid.

F. Kesimpulan Chapter 3

Percobaan	Hasil Utama
Scaling sebelum SVM	Akurasi naik dari 93.71% menjadi 96.50%
PCA (2 komponen)	Menjelaskan 63.24% variansi, kelas masih terpisah cukup jelas
K-Means (k=2)	Kesesuaian 90.69% dengan label asli
Agglomerative (k=2)	Kesesuaian 90.69% dengan label asli
DBSCAN vs K-Means (two_moons)	DBSCAN unggul pada cluster berbentuk non-konveks

Kendala Teknis: Bagian Kode pada Buku yang Sudah Tidak Dapat Dijalankan

Buku "Introduction to Machine Learning with Python" ditulis pada tahun 2016 menggunakan scikit-learn versi lama. Karena Google Colab selalu memakai versi library terbaru, beberapa baris kode asli pada Bab 2 dan Bab 3 buku akan menghasilkan error jika dijalankan apa adanya. Bagian ini merangkum kendala tersebut beserta penyebab dan solusinya, agar dapat dibedakan dari hasil percobaan pada Bab II dan III di atas, yang sengaja menggunakan pendekatan/dataset pengganti untuk menghindari error-error berikut.

1. `load_boston()` — Dataset Boston Housing (Chapter 2)

Kode: `from sklearn.datasets import load_boston`

Status: TIDAK BISA DIPAKAI LAGI (dihapus total sejak scikit-learn 1.2, dirilis akhir 2022).

Penyebab: Dataset Boston Housing mengandung fitur bernama "B" yang dibuat dengan asumsi bahwa segregasi rasial berpengaruh positif terhadap harga rumah. Karena masalah etis ini, tim scikit-learn menghapus fungsi `load_boston()` sepenuhnya, bukan sekadar men-deprecate-nya — memanggil fungsi ini sekarang langsung menghasilkan `ImportError`, bukan warning.

Dampak pada buku: Dataset ini dipakai di sepanjang bagian regresi Bab 2 — mulai dari pengenalan dataset, dilanjutkan fungsi `mglearn.datasets.load_extended_boston()` (yang juga otomatis ikut error karena bergantung pada `load_boston`), hingga seluruh contoh Ridge Regression, Lasso, dan analisis pengaruh regularisasi (α) yang memakai dataset tersebut.

Solusi yang disarankan: Ganti dengan `sklearn.datasets.fetch_california_housing()` sebagai dataset regresi alternatif, atau — seperti yang dilakukan pada Bab 2.2 laporan ini — gunakan

dataset sintetis (mis. data 'wave' yang diperluas dengan fitur polinomial) untuk tetap mendemonstrasikan konsep yang sama (perbandingan Linear Regression, Ridge, dan Lasso pada data berdimensi tinggi).

2. `from preamble import *` (semua chapter)

Kode: `%matplotlib inline` lalu `from preamble import *`

Status: ERROR di Colab bila notebook dibuka satuan (bukan clone repo utuh).

Penyebab: `preamble.py` bukan bagian dari suatu library yang bisa di-install lewat `pip`, melainkan file konfigurasi milik repository buku. Saat notebook dibuka lewat menu `File > Open notebook > GitHub` di Colab, hanya file `.ipynb` yang diambil — file `preamble.py` dan folder `mglearn/` di repo yang sama tidak ikut ter-copy, sehingga Python tidak menemukan modul tersebut (`ModuleNotFoundError: No module named 'preamble'`).

Solusi: clone seluruh repository terlebih dahulu (`!git clone https://github.com/amueller/introduction_to_ml_with_python.git` lalu `%cd` ke folder hasil clone) sebelum menjalankan cell import, seperti telah dibahas pada sesi konsultasi sebelumnya.

3. `set_matplotlib_formats` dari `IPython.display`

Kode: `from IPython.display import set_matplotlib_formats` (baris pertama file `preamble.py`).

Status: BERPOTENSI ERROR tergantung versi IPython yang terpasang di Colab (fungsi ini sudah dipindahkan sejak IPython 7.23 dan tidak lagi tersedia di lokasi lama pada versi-versi terbaru).

Solusi: ganti menjadi `from matplotlib_inline.backend_inline import set_matplotlib_formats`, atau hapus baris tersebut jika hanya dipakai untuk mengatur format gambar (tidak wajib agar kode inti tetap berjalan).

4. `mglearn.plots.plot_group_kfold`

Status: DIGANTI NAMA menjadi `plot_label_kfold` pada cetakan pertama buku (errata resmi dari penulis), akibat penyesuaian penamaan pada modul `model_selection` scikit-learn. Kode pada cetakan pertama buku yang masih memanggil `plot_group_kfold` akan menghasilkan `AttributeError` pada versi `mglearn` terbaru.

5. Instalasi Graphviz untuk Visualisasi Decision Tree

Status: SERING ERROR jika hanya mengandalkan `pip install graphviz`.

Penyebab: Visualisasi pohon keputusan (`export_graphviz`) pada Bab 2 membutuhkan program `graphviz` di tingkat sistem operasi, bukan cuma package Python. Instalasi `pip install graphviz` saja tidak cukup di Colab.

Solusi: tambahkan `!apt-get install -y graphviz` sebelum menjalankan cell visualisasi pohon keputusan.

6. Ringkasan

Bagian Kode Buku	Status	Penyebab Utama
<code>load_boston() / load_extended_boston()</code>	Dihapus total (error)	Masalah etis dataset, dihapus sejak <code>sklearn</code> 1.2
<code>from preamble import *</code>	Error jika notebook dibuka satuan	File repo tidak ikut ter-copy di Colab
<code>set_matplotlib_formats</code> (dari <code>IPython.display</code>)	Berpotensi error tergantung versi	Lokasi fungsi dipindahkan sejak <code>IPython</code> 7.23
<code>mglearn.plots.plot_group_kfold</code>	Diganti nama	Rename mengikuti perubahan <code>scikit-learn</code>
Visualisasi Decision Tree (<code>graphviz</code>)	Error tanpa setup tambahan	Perlu program sistem, bukan cuma <code>pip package</code>

Karena kendala-kendala di atas, seluruh percobaan pada Bab II dan III laporan ini sengaja disusun ulang menggunakan dataset dan pendekatan yang setara secara konsep dengan versi asli buku, namun tetap kompatibel dengan versi `scikit-learn` terbaru yang berjalan di Google Colab saat laporan ini dibuat.

Kesimpulan

- 1) Pemilihan hyperparameter ($n_neighbors$, C , α , max_depth , k) sangat memengaruhi keseimbangan antara underfitting dan overfitting pada model supervised learning.
- 2) Model ensemble seperti Random Forest umumnya lebih tahan terhadap overfitting dibandingkan model tunggal seperti Decision Tree.
- 3) Regularisasi L1 (Lasso) dapat digunakan sekaligus sebagai metode seleksi fitur otomatis.
- 4) Preprocessing data, terutama feature scaling, sangat penting untuk algoritma yang sensitif terhadap skala fitur seperti SVM dan KNN.
- 5) PCA efektif untuk mereduksi dimensi data sekaligus mempertahankan sebagian besar informasi yang relevan untuk visualisasi maupun analisis lanjutan.
- 6) Pemilihan algoritma clustering harus mempertimbangkan bentuk sebaran data: K-Means dan Agglomerative Clustering cocok untuk cluster berbentuk cembung, sedangkan DBSCAN lebih unggul untuk cluster berbentuk non-konveks dan mampu mendeteksi noise.